

[IBM StreamSets] DB to DB Pipeline 생성 가이드

References

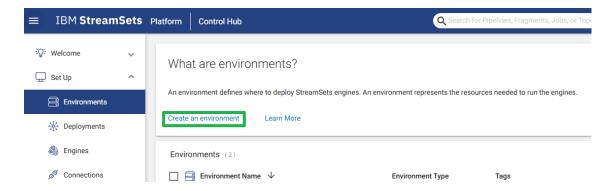
- IBM StreamSets Data Collector Engine Guide
- IBM StreamSets Transformer Engine Guide

* 사전 세팅

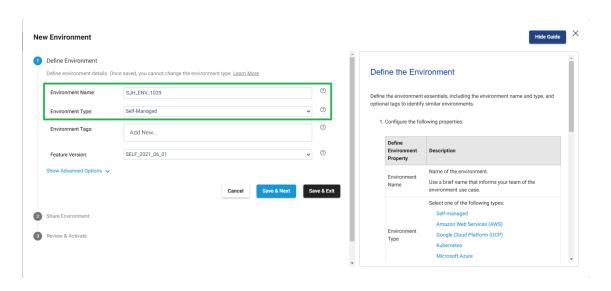
- DB 구성 가이드 에서는 PostgreSQL 사용
- Self Managed VM 최소 사양 2 Core, 1 GB RAM, 6 GB Disk space, 32768 File descriptors
- 엔진을 배포 할 각 VM (Datacollector, Transformer) 에 Docker 설치

STEP 1. Environments 생성

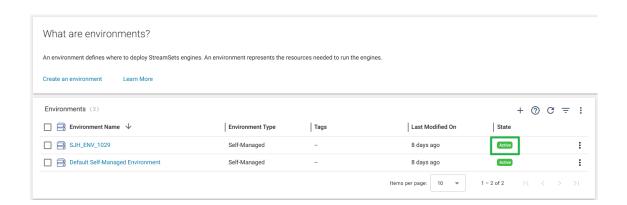
- Environments 는 StreamSets 엔진 (Data Collector, Transformer) 의 배포 위치를 정의
- Environment Type 은 Self-managed, AWS, GCP, Azure, Kubernetes 로 선택 가능



IBM StreamSets 플랫폼 메인 화면에서 Environments 탭 클릭 > Create an environment 클릭



자체 VM에 엔진을 배포할 경우 Self-Managed 를 클릭하고 Save & Exit



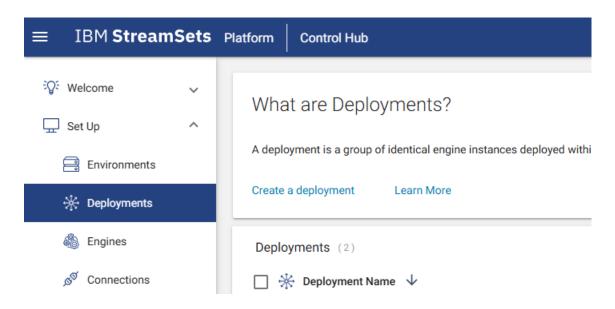
Activate 된 Environment State 확인

STEP 2. Data Collector 생성 및 배포

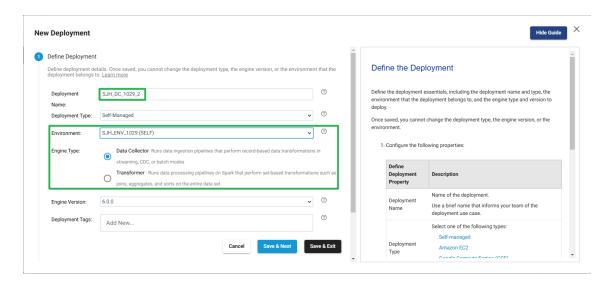
• Data Collector 인스턴스 그룹 생성

[참고] Docker 설치 스크립트 - 각 VM 에 사전 설치

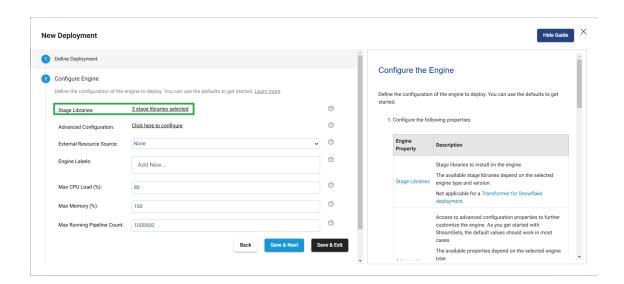
```
$ yum remove -y docker \
docker-client \
docker-client-latest \
docker-common \
docker-latest \
docker-latest-logrotate \
docker-logrotate \
docker-engine
$ yum install -y yum-utils
$ yum-config-manager \
--add-repo \
https://download.docker.com/linux/centos/docker-ce.repo
$ yum update -y && yum install -y docker-ce docker-ce-cli containerd.io
$ systemctl start docker && systemctl enable --now docker
## Docker version 체크
$ docker version
```



Deployments 탭 > Create a deployment 클릭



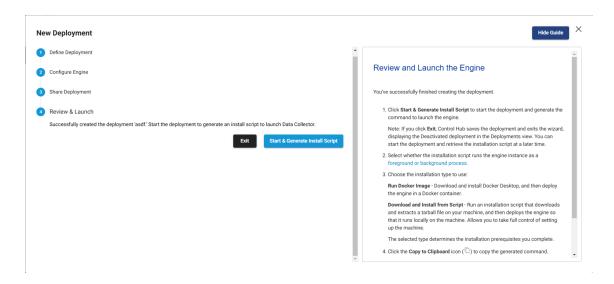
Deployment 명 입력, Data Collector 선택 후 Save & Next



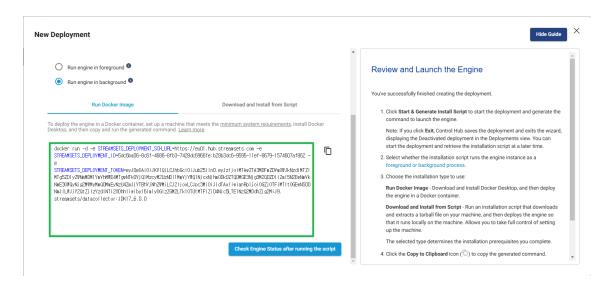
엔진에 설치할 라이브러리를 선택하기 위해 Stage Libraries 를 클릭



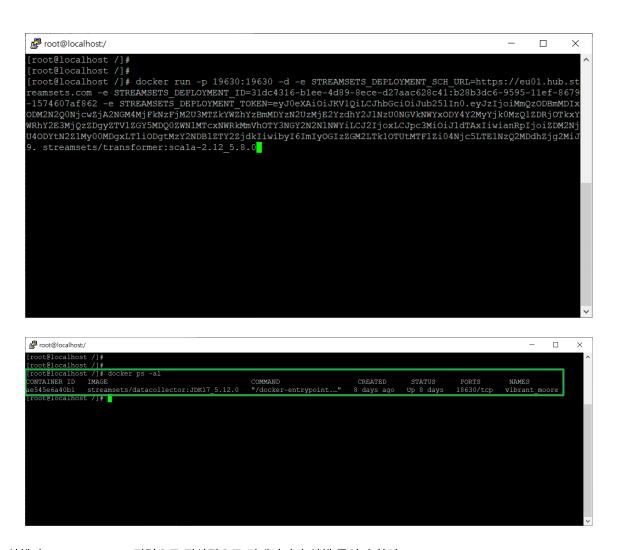
각 Stage 에서 사용할 라이브러리를 설치 편의상 JDBC, Snowflake 관련 라이브러리를 모두 선택



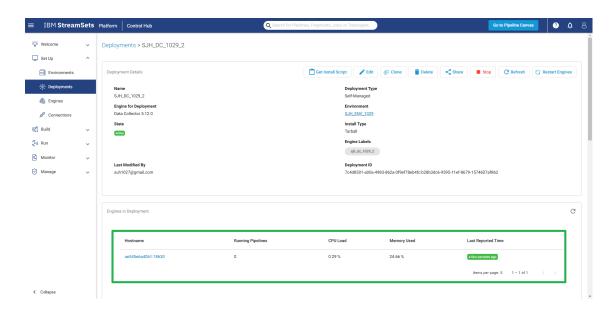
Share Deployment 생략, Review & Launch 에서 엔진 설치 스크립트 생성



생성 된 스크립트를 복사하여 Data Collector 로 사용 할 VM 에 실행 후 Check Engine... 클릭



실행 후 docker ps -al 명령으로 정상적으로 컨테이너가 실행 중인지 확인

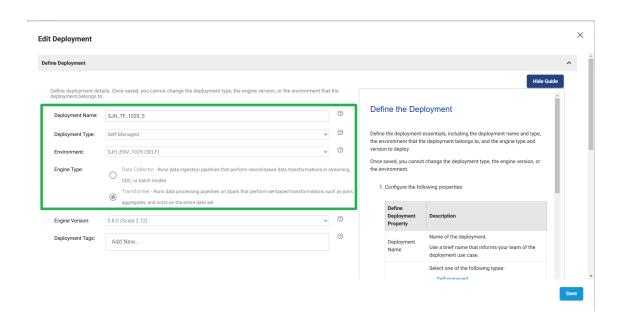


설치 및 실행이 완료 되면, Engines in Deloyment 에서 실행 중인 컨테이너가 확인 가능하다.

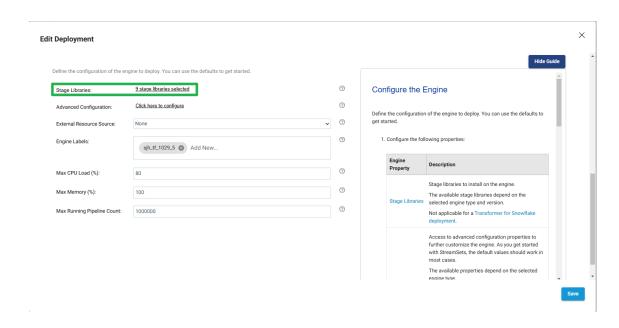
Container ID : 포트 로 구분 가능

STEP 3. Transformer 생성 및 배포

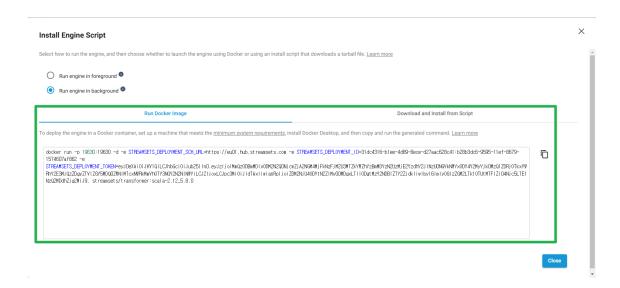
• Transformer 인스턴스 그룹 생성



Data Collector 와 설치 과정은 동일하며, Deloyment 명, Environment, Engine Type 선택 후 Next



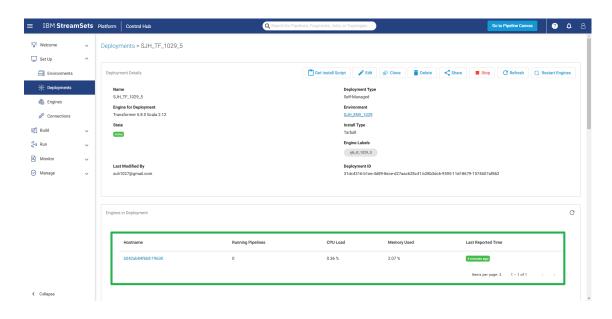
Stage Libraries 클릭 후 JDBC, Snowflake 관련 라이브러리 모두 선택



백그라운드 실행 및 Docker Image 로 선택하여 스크립트 복사 후 VM 에서 실행

```
| Comparison of the Comparison
```

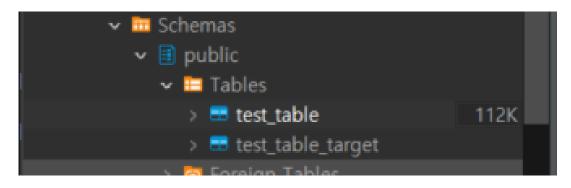
docker ps -al 명령으로 컨테이너 실행 확인



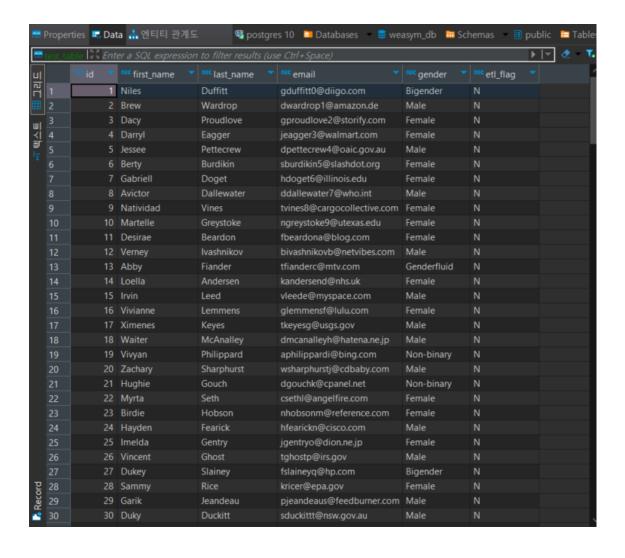
엔진 실행 확인

STEP 4. DB to DB Pipeline 생성

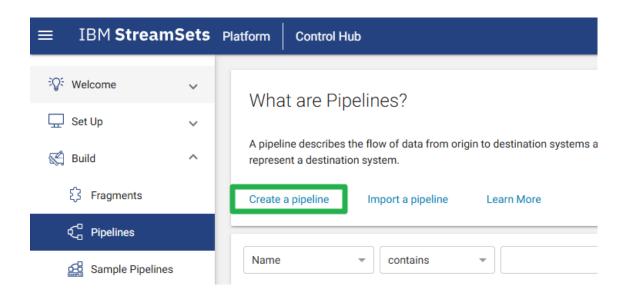
- 더미 데이터를 사용한 Pipeline 생성 Tutorial
- <u>파일 다운로드 링크</u> MOCK_DATA.csv 다운로드



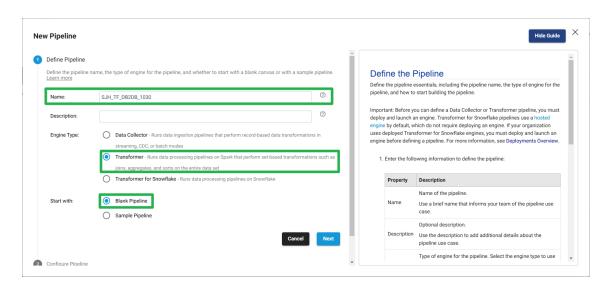
미리 생성해둔 DB에 TEST_TABLE, TEST_TABLE_TARGET 의 명칭으로 두개의 테이블을 생성.



TEST_TABLE 에는 별도의 DB Tool 을 사용, MOCK_DATA 파일 내 데이터를 가져와 데이터를 입력한다. 편의상 에러 방지를 위해 컬럼의 크기는 최대로 늘려서 세팅



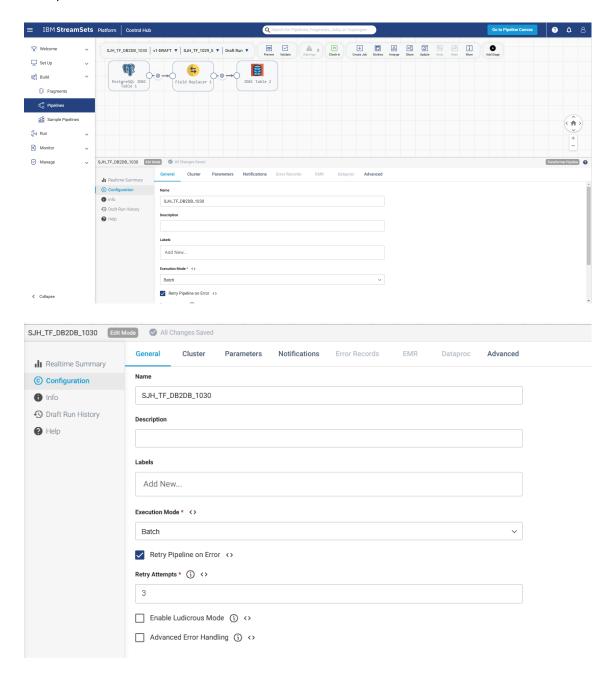
Build > Pipelines 탭에서 Create a pipeline 을 클릭하여 파이프라인 생성



Transformer 파이프라인에 있는 Stage를 사용하여 테스트를 진행하기 위해 Transformer 엔진 선택 Pipeline Engine 은 3개의 타입이 있으며 각 타입은 다음과 같은 특징을 갖는다.

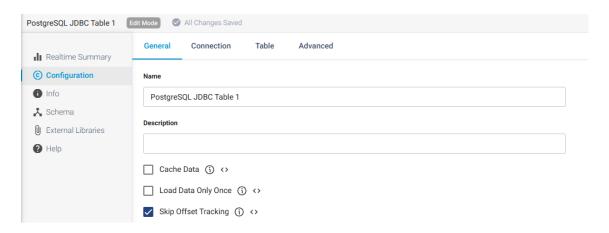
Data Collector	스트리밍, CDC 또는 Batch 처리 모드에서 레코드 기반 데이터 파이프라인 수행
Transformer	Apache Spark에서 실행되는 데이터 처리 파이프라인을 실행, Transformer 파이프라인은 클러스터에 배포된 Spark에서 실행되므로 전체 데이터 세트에서 조인, 집계 및 정렬과 같은 세트 기반 변환을 수행
Transformer for Snowflake	파이프라인 구성에 따라 SQL 쿼리를 생성하고 쿼리를 Snowflake에 전달하여 실행. Snowflake 파이프라인은 Snowpark DataFrame 기반 처리를 사용하여 Snowflake 테이블에서 읽고 쓰기를 수행

생성한 Pipeline Canvas 화면

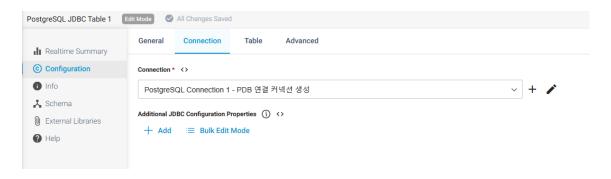


Pipeline 전체 General 설정 예시

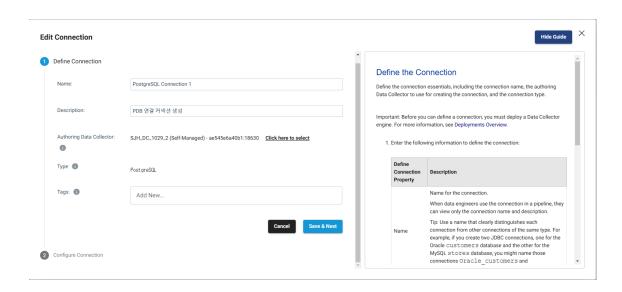
Excution Mode 와 Error 시 Retry 여부, 횟수를 설정할 수 있다.



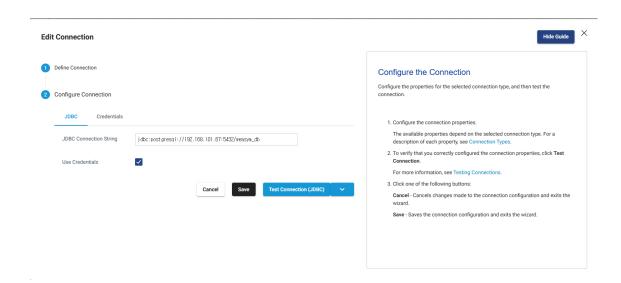
PostgreSQL JDBC Table1 스테이지 General 탭 설정 예시



Connection 탭 예시, + 를 눌러 커넥션을 생성하거나, 생성 된 커넥션을 수정할 수 있다.



Connection 탭에서 Connection 컴포넌트를 생성할 수 있다. Connection 명과 Description, Data Collector 엔진을 선택



미리 생성해 둔 DB의 JDBC Connection String 을 입력하고, Credential 을 입력 후 Connection 테스트 후 Save

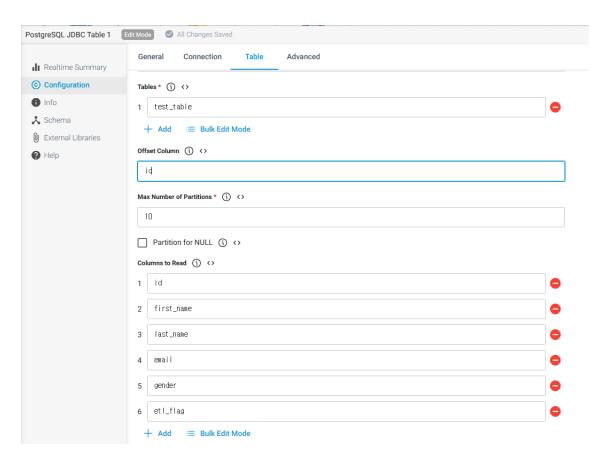
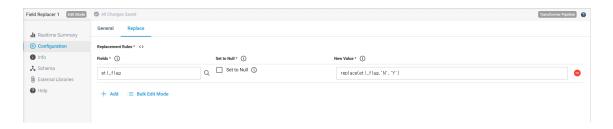


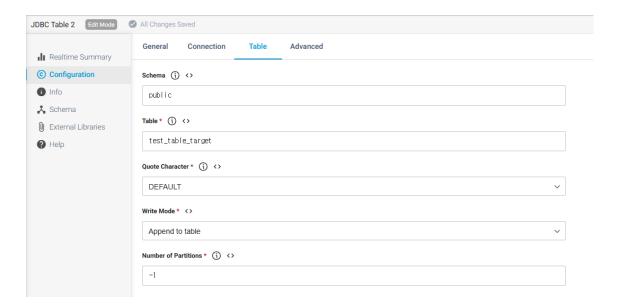
Table 탭 설정 예시

Offset Column 은 파이프라인 실행 시 처리 된 행을 구분하기 위한 컬럼으로, Primary Key 값을 주로 사용한다.



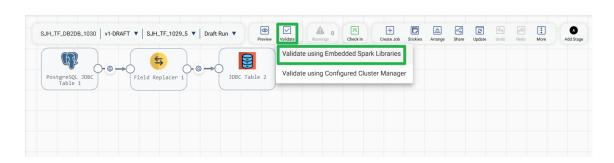
Field Replacer 1 Stage > Replace 탭 설정 예시

ETL_FLAG 필드의 값을 N \rightarrow Y 로 Relplace 하는 함수를 Value 값에 입력한다. replace(etl_flag,'N','Y')

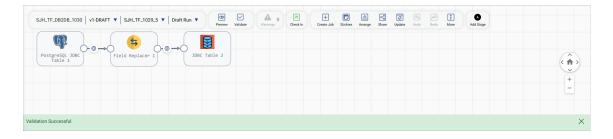


JDBC Table 2 스테이지의 커넥션의 생성 방법은 PostgreSQL JDBC Table1 스테이지와 동일하다. Table 탭 의 설정은 Target DB 의 스키마와 테이블 지정.

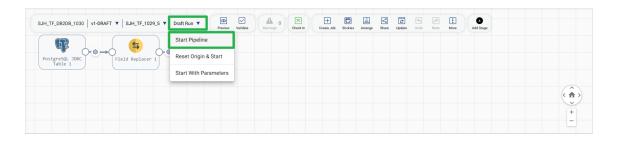
STEP 5. 생성 된 파이프라인 검증 및 실행



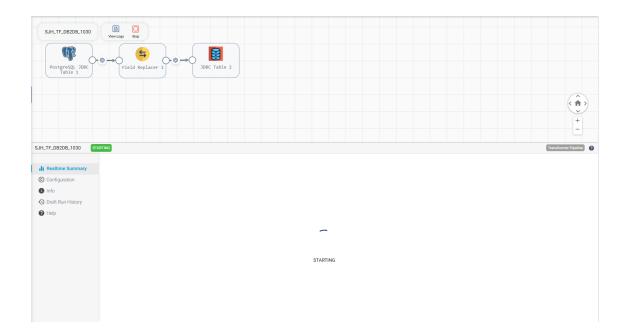
Transformer 에 내장 된 Spark Libraries 를 사용하여 생성 한 Pipeline 을 Validation 한다.

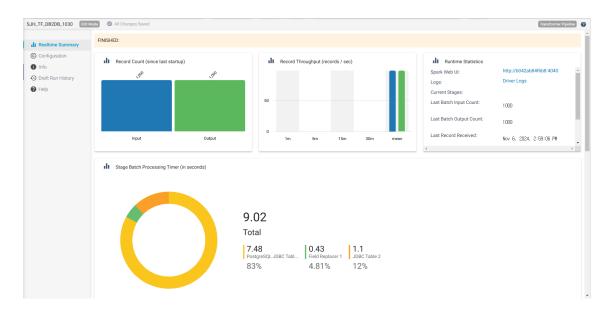


Validation 성공 예시

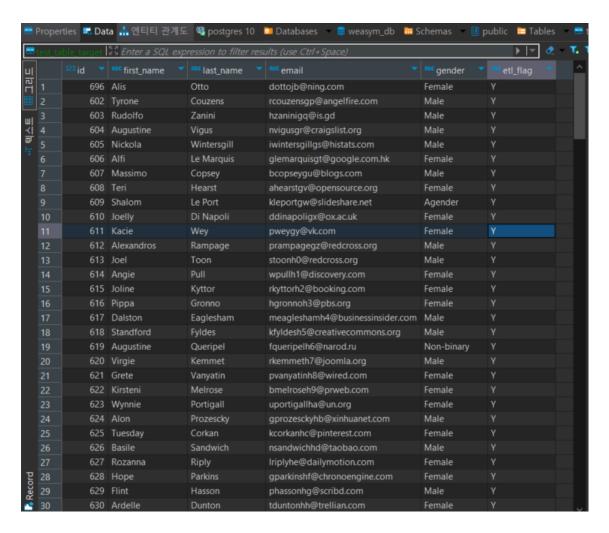


Draft Run 을 클릭하여 Start Pipeline, 또는 Origin Reset 후 Start 할 수 있다.

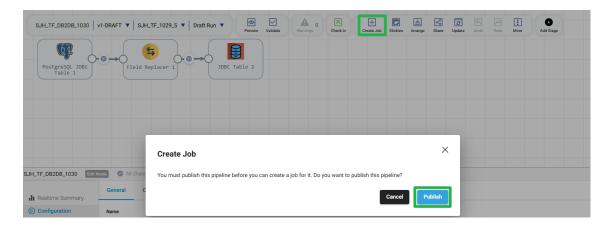




처리 중 각 스테이지를 클릭하여 처리 현황을 대시보드로 실시간 확인할 수 있다.



처리 완료 된 TEST_TABLE_TARGET 데이터 목록



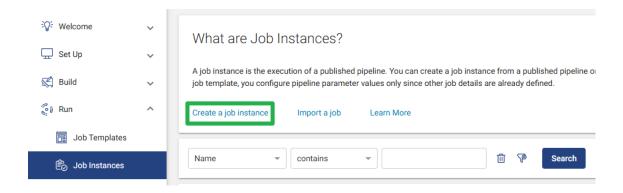
생성 완료 된 Pipeline 는 Publish 해야 Job Instance 생성이 가능하다.



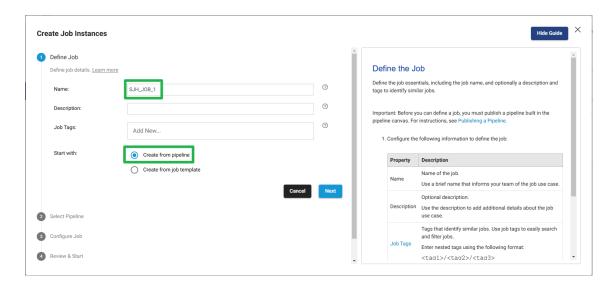
Publish 된 Pipeline 은 Read Only Mode 로 변경.

STEP 6. Job Instance & Schedule 생성

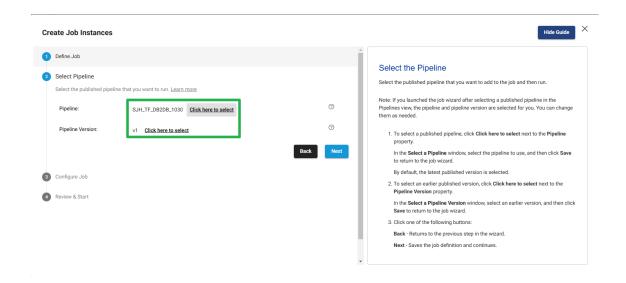
- Job 을 생성하여 Publish 된 파이프라인 실행 할 수 있다.
- 생성 된 Job 으로 주기적으로 Pipeline 을 실행 시킬 수 있다.



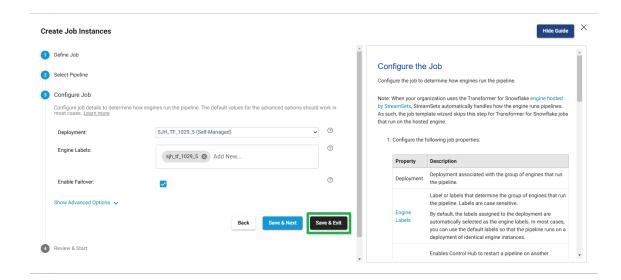
Run > Job Instances 탭 > Create a job instance 를 클릭하여 job을 생성한다.



Job 컴포넌트 명, Create from pipeline 선택



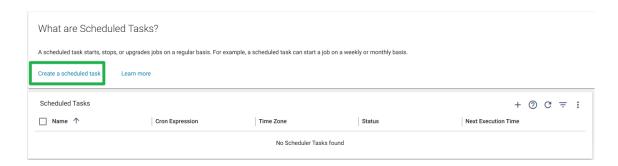
게시 된 파이프라인 및 버전을 선택 후 Next



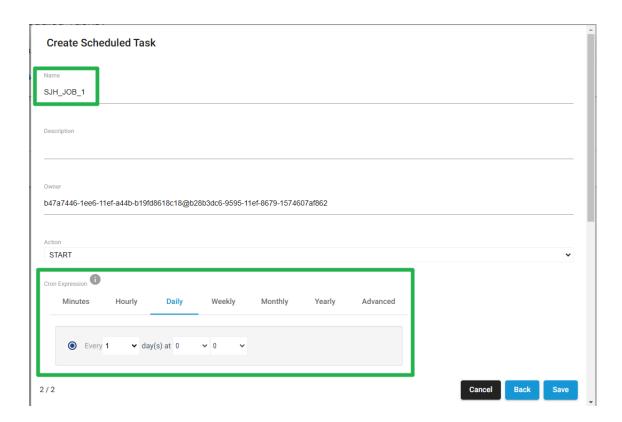
Save & Exit



실행 중인 Pipeline 상태를 Job instaces 탭에서 실시간으로 확인 가능하다.



Scheduled Tasks 탭 > Create a scheduled task 를 클릭하여 Job 의 주기적 실행이 가능하도록 설정 가능 하다.



Cron 의 설정과 유사하며, 생성 된 Job 을 선택 하여 설정 가능.

* Data Collector, Transformer 엔진 내 (Docker) 실행 이력 로그 확인 방법

```
root@localhost:~
ransformer@b042ab84f6b8:/data/transformer$
transformer@b042ab84f6b8:/data/transformer$
transformer@b042ab84f6b8:/data/transformer$
transformer@b042ab84f6b8:/data/transformer$
transformer@b042ab84f6b8:/data/transformer$ pwd
transformer@b042ab84f6b8:/data/transformer$
transformer@b042ab84f6b8:/data/transformer$ ls -al
total 300
drwxr-xr-x. 1 transformer transformer
                                           219 Nov 6 06:43 .
                                            25 Jun 25 09:07 .
drwxr-xr-x. 1 root
                           root
                                           27 Oct 29 04:19 blobstore
195 Oct 29 04:20 control-hub-pushed.properties
-rw-----. 1 transformer transformer 1526 Nov 6 06:43 meteringSnapshot.json
                                           65 Nov 5 21:05 opt-stats.json
4096 Nov 6 06:08 pipelines
drwxr-xr-x. 4 transformer transformer
                                          4096 Nov
drwxr-xr-x. 5 transformer transformer
                                           249 Nov 6 06:08 runHistory
                                          4096 Nov 6 06:08 runInfo
36 Oct 29 04:19 sdc.id
       ---. 1 transformer transformer 275744 Nov 6 06:43 stats.json
-rw-----. 1 transformer transformer 1528 Nov 6 06:43 statsSnapshot.json
transformer@b042ab84f6b8:/data/transformer$
```

```
## Transformer 엔진 내부 확인
$ cd /data/transformer
$ 1s -a1
drwxr-xr-x. 1 transformer transformer
                                       219 Nov 6 06:43
drwxr-xr-x. 1 root
                         root
                                        25 Jun 25 09:07 ...
drwxr-xr-x, 2 transformer transformer
                                        27 Oct 29 04:19 blobstore
-rw-r--r-- 1 transformer transformer
                                       195 Oct 29 04:20 control-hub-pushed.
-rw----- 1 transformer transformer
                                      1526 Nov 6 06:43 meteringSnapshot js
-rw-r--r-- 1 transformer transformer
                                        65 Nov 5 21:05 opt-stats.json
drwxr-xr-x. 4 transformer transformer
                                       4096 Nov 6 06:08 pipelines
drwxr-xr-x. 5 transformer transformer
                                       249 Nov 6 06:08 runHistory
drwxr-xr-x. 4 transformer transformer
                                      4096 Nov 6 06:08 runInfo
-rw-r--r-- 1 transformer transformer
                                        36 Oct 29 04:19 sdc.id
-rw-----. 1 transformer transformer 275744 Nov 6 06:43 stats.json
-rw-----. 1 transformer transformer
                                      1528 Nov 6 06:43 statsSnapshot.json
## runHistory 폴더 내 에서 실행 이력 확인 가능
## 하위 폴더를 Container 안에서 밖으로 Copy 후 파일 확인 (docker cp 명령 사용)
$ docker cp trusting_wilson:/data/transformer /back
Successfully copied 5.59MB to /back
```